



Uniwersytet Rzeszowski
Kolegium Nauk Przyrodniczych
Instytut Informatyki

Metody Statystyki Matematycznej

Lab 2

Klastering

Prowadzący:

Dr Lech Zaręba

Autor:

Jakub Flis

117794


Rzeszów 2024

1. Wstęp

Klastering hierarchiczny jest metodą, która tworzy hierarchię klastrów w postaci drzewa dendrogramowego. Obliczono macierz odległości przy użyciu metody euklidesowej. Macierz ta określa odległości między wszystkimi parami obserwacji w zbiorze danych. Wykorzystano metodę aglomeracyjną Ward.D2, która minimalizuje sumę kwadratów odchyleń w klastrach. Utworzono dendrogram, aby wizualizować hierarchiczną strukturę klastrów. Dendrogram pokazuje, w jaki sposób klasterzy łączą się na różnych poziomach agregacji. Na podstawie dendrogramu przypisano obserwacje do trzech klastrów. Każda obserwacja została przydzielona do klastra, który minimalizował odległość wewnątrz klastra.

Metoda K-means jest niehierarchiczną metodą klasteringu, która dzieli dane na k klastrów, gdzie każda obserwacja należy do klastra z najbliższym środkiem (centroidem). Dla każdego klastra obliczono średnie wartości zmiennych.

Metoda PAM to alternatywa dla K-średnich, która używa medoidów zamiast centroidów, co sprawia, że jest bardziej odporna na szumy i outlajery. Medoidy są reprezentatywnymi punktami dla każdego klastra, które minimalizują sumę odległości od wszystkich punktów w klastrze.



Aby ocenić jakość klasteringu, użyto różnych statystyk porównawczych, takich jak: wb.ratio, pearsongamma, i dunn2. Niższy wb.ratio, wyższy pearsongamma, i wyższy dunn2 wskazują na lepszy klastering.

Analiza wariancji (ANOVA) została zastosowana, aby ocenić, czy zmienne istotnie różnicują klasterzy. Statystycznie istotne różnice sugerują, że zmienne mają znaczący wpływ na podział na klasterzy.


2. Źródło danych

<https://www.kaggle.com/datasets/dev0914sharma/customer-clustering/data>

Podstawowe dane na temat klientów.

Liczba rekordów: 2000


Liczba kolumn: 8

ID	# Sex	# Marital status	# Age	# Education
				
100m 100m	0 1	0 1	18 76	0 3
100000001	0	0	67	2
100000002	1	1	22	1
100000003	0	0	49	1
100000004	0	0	45	1
100000005	0	0	53	1

# Income	# Occupation	# Settlement size
		
35.8k 309k	0 2	0 2
124670	1	2
150773	1	2
89210	0	0
171565	1	1


3. Przygotowanie modelu

Dendrogram dla k=3:



```
$cluster.size
[1] 10 7 3
```

K-means clustering with 3 clusters of sizes 4, 3, 13



```
$cluster.size
[1] 3 7 7 3
```

K-means clustering with 4 clusters of sizes 3, 3, 6, 8

Średnie wartości dla klastrów w k-means.

```
cluster3$centers
```

##	Sex	Marital.status	Age	Education	Income	Occupation
## 1	0.3333333	0.6666667	-0.2699816	0.4223180	1.66508511	1.7168098
## 2	0.0000000	0.3333333	1.5832821	1.6289408	-0.46325485	-0.8844172
## 3	0.0000000	0.0000000	0.5765709	-0.1809934	-0.03921418	-0.3641718
## 4	0.7500000	0.7500000	-0.9249159	-0.6334770	-0.42127571	-0.0390184

4. Wnioski

- Potrzebne było dodanie do bazy kolumny która będzie identyfikowała poszczególne obiekty.
- Dla przejrzystości ograniczono bazę z 2000 rekordów do 20.
- Numeracja klastrów nie pokrywa się z kolejnością na dendrogramie, ale przynależność obiektów do danego klastra zgadza się.
- Przy podziale na 4 klastry hierarchiczne liczebność obiektów jest bardziej równomierna.

- Przy podziale na 4 klastry hierarchiczne stosunek odległości wewnętrznych do zewnętrznych jest mniejszy i lepszy.
- Podział na 3 klastry hierarchiczne ma lepszą separację między klastrami według indeksu Dunna.
- Na podstawie wartości średnich każdego z 4 klastrów, możemy zauważyć podział konsumentów na konkretne grupy: np. grupa osób zamężnych z dobrą karierą, albo na grupy kobiety, które są mniej zamożne.
- Podziały na klastry hierarchiczne i k-means są dość podobne, znacznie różnią się od klastrów medoidów.

##	Id	srednia na 4	srednia na 3	med na 4	med na 3	dend4	dend3
## 1	1	4	2	1	1	1	1
## 2	2	2	3	2	2	2	2
## 3	3	4	2	1	1	3	1
## 4	4	1	1	3	3	3	1
## 5	5	1	1	3	3	3	1
## 6	6	1	2	3	3	3	1
## 7	7	1	1	3	3	3	1
## 8	8	3	1	3	3	4	3
## 9	9	4	2	1	1	1	1
## 10	10	3	1	3	3	4	3
## 11	11	2	3	2	2	2	2
## 12	12	2	3	2	2	2	2
## 13	13	2	3	2	2	2	2
## 14	14	4	2	1	1	1	1
## 15	15	2	3	2	2	2	2
## 16	16	2	3	2	2	3	1
## 17	17	1	2	3	3	3	1
## 18	18	1	1	4	3	2	2
## 19	19	3	1	3	3	4	3
## 20	20	1	1	4	3	2	2