



Uniwersytet Rzeszowski
Kolegium Nauk Przyrodniczych
Instytut Informatyki

Metody Statystyki Matematycznej

Laboratorium

Analiza korespondencji

Prowadzący:

Dr Lech Zaręba

Autor:

Jakub Flis

117794

Rzeszów 2024

1. Wstęp

Analiza korespondencji to opisowa i eksploracyjna technika analizy tablic dwudzielczych i wielodzielczych, zawierających pewne miary charakteryzujące powiązanie między kolumnami i wierszami. Otrzymywane wyniki dostarczają informacji podobnych w swej naturze do analizy PCA. Pozwalają na analizę struktury zmiennych jakościowych tworzących tablicę. Najczęściej spotykaną tablicą tego typu jest dwuwymiarowa tablica kontyngencji.

Podstawą analizy korespondencji jest pojęcie masy: częstości względne pokazują, jak jednostka masy jest rozłożona na poszczególne komórki. Sumy częstości względnych dla poszczególnych wierszy i kolumn nazywane są odpowiednio masą wiersza i masą kolumny.

2. Baza danych

	A	B	C	D
1	Nationality	Food	Juice	Dessert
2	Indian	Traditional food	Fresh Juice	Maybe
3	Indian	Western Food	Carbonated drinks	Yes
4	Indian	Western Food	Fresh Juice	Maybe
5	Indian	Traditional food	Fresh Juice	Maybe
6	Indian	Traditional food	Fresh Juice	Maybe
7	Indian	Traditional food	Fresh Juice	Yes
8	Indian	Traditional food	Fresh Juice	Yes
9	Pakistani	Western Food	Carbonated drinks	Yes
10	Indian	Traditional food	Fresh Juice	Yes
11	Indian	Western Food	Fresh Juice	Yes
12	Indian	Traditional food	Fresh Juice	Yes
13	Indonesia	Traditional food	Fresh Juice	Maybe

Baza danych jest zmodyfikowaną wersją rzeczywistych danych z <https://www.kaggle.com/datasets/vijayashreer/food-preferences>.

Dane wykorzystane w ćwiczeniu składają się z 4 kolumn zawierających zmienne jakościowe. Są to 274 rekordy z informacjami na temat preferowanych zamówień w restauracji przez obywateli różnych narodowości.

Kolumny to: narodowość, preferowany styl kulinarny, preferowany napój oraz ochota na deser. Poniżej przedstawiono unikalne kategorie dla każdej kolumny:

```
> cats<- apply(x, 2, function(x) nlevels(as.factor(x)))
> print(cats)
Nationality      Food      Juice      Dessert
          4          2          2          3
```

```

> unique(pop[1])
  Nationality
1      Indian
8   Pakistani
12 Indonesian
15   Malaysian
> unique(pop[2])
      Food
1 Traditional food
2   Western Food
> unique(pop[3])
      Juice
1   Fresh Juice
2 Carbonated drinks
> unique(pop[4])
  Dessert
1   Maybe
2     Yes
15    No

```

Poniżej przedstawiono liczebności każdej z kategorii:

```

> nationality_counts <- table(pop$Nationality)
> nationality_counts

      Indian Indonesian   Malaysian   Pakistani
      241         10         16          6
>
> food_counts <- table(pop$Food)
> food_counts

Traditional food   Western Food
      228           45
>
> juice_counts <- table(pop$Juice)
> juice_counts

Carbonated drinks   Fresh Juice
      30            243
>
> dessert_counts <- table(pop$Dessert)
> dessert_counts

Maybe   No   Yes
  117    48  108


```

3. Analiza korespondencji

Funkcję z biblioteki MCA wywołano z użyciem tablicy Burta: tablica Burta jest iloczynem wewnętrznym macierzy układu, a wyniki wielowymiarowej analizy korespondencji są takie same, jak wyniki, jakie otrzymalibyśmy dla punktów reprezentujących kolumny przy zastosowaniu prostej analizy korespondencji do macierzy układu.

```
res.mca <- MCA(df1.active,ncp = 2, graph = TRUE,method = "Burt")
```

```
summary(res.mca)
```



Wykres reprezentacji zmiennych pokazuje, jak kategorie zmiennych są rozmieszczone w przestrzeni czynnikowej. Współrzędne kategorii pokazują, jak dana kategoria zmiennej przyczynia się do danego wymiaru. Wykres ten pomaga w identyfikacji relacji między kategoriami zmiennych i wymiarami. Zazwyczaj przeprowadzamy go dla dwóch wymiarów.

Dim.1 wyjaśnia 31.018% wariancji, co oznacza, że jest to najważniejszy wymiar w tej analizie, mają na niego duży wpływ zmienne Food i Juice.

Wykres mapy czynnikowej pokazuje, że na drugi wymiar duży wpływ mają kategorie związane z deserami, a na pierwszy wymiar kategorie takie jak napój gazowany, styl zachodni, czy narodowość Pakistańska. Ponadto można od razu wyróżnić narodowość Indonezyjską, która ma drastyczny wpływ na drugi wymiar.

Sprawdzone zostały poszczególne aspekty korespondencji.

Wartości własne reprezentują ilość wariancji wyjaśnionej przez poszczególne wymiary (czynniki).

Kolumny:

- Variance: Ilość wariancji wyjaśnionej przez dany wymiar.
- % of var.: Procent całkowitej wariancji wyjaśnionej przez dany wymiar.
- Cumulative % of var.: Skumulowany procent wariancji wyjaśnionej przez kolejne wymiary

7 wymiarów w całości wyjaśnia całą wariancję w próbce.

Eigenvalues

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5	Dim.6	Dim.7
Variance	0.144	0.078	0.063	0.056	0.048	0.041	0.033
% of var.	31.018	16.900	13.695	12.019	10.283	8.889	7.195
Cumulative % of var.	31.018	47.918	61.613	73.632	83.915	92.805	100.000

Jak widać, dwa pierwsze wymiary reprezentują 47.9% całkowitej wariancji.

Individuals (the 10 first)

	Dim.1	ctr	cos2	Dim.2	ctr	cos2
1	-0.331	0.106	0.246	0.335	0.147	0.251
2	1.583	2.424	0.676	-0.252	0.083	0.017
3	0.382	0.141	0.088	0.328	0.141	0.065
4	-0.331	0.106	0.246	0.335	0.147	0.251
5	-0.331	0.106	0.246	0.335	0.147	0.251
6	-0.012	0.000	0.000	-0.253	0.084	0.129
7	-0.012	0.000	0.000	-0.253	0.084	0.129
8	2.558	6.325	0.442	-0.216	0.061	0.003
9	-0.012	0.000	0.000	-0.253	0.084	0.129
10	0.701	0.475	0.287	-0.260	0.089	0.039

Dla każdej obserwacji pokazane są:

- Dim.1, Dim.2: Współrzędne na pierwszym i drugim wymiarze.
- ctr: Wkład obserwacji do wyjaśnienia wariancji danego wymiaru.
- cos2: Cosinus kwadratu kąta między wektorem obserwacji a osią wymiaru, miara jakości reprezentacji.

Jak widać obserwacja 8 odpowiada za umiarkowaną część wariancji wymiaru 1.

8	Indian	Traditional food	Fresh Juice	Yes
---	--------	------------------	-------------	-----

Można to też potwierdzić z wykresem mapy czynnikowej.

Na poniższej analizie kategorii widzimy, że kategorie Pakistani, Malaysian, Western Food, Carbonated Drinks znajdują się daleko na osi wymiaru 1 i dzięki temu mają większy wpływ ctr na wariancję tego wymiaru, ale nie jest to do końca proporcjonalne – Pakistani ma mniejszy ctr niż Western Food.


Wysoka wartość bezwzględna v.test świadczy o tym, że dana cecha jest bardzo istotna dla danego wymiaru. Największe znaczenie dla dim.1 miałyby wówczas kategoria Carbonated drink. Co ciekawe, dokładnie takie samo znaczenie, ale przeciwne, ma kategoria Fresh juice.

Categories (the 10 first)								
	Dim.1	ctr	cos2	v.test	Dim.2	ctr	cos2	v.test
Indian	-0.089	1.225	0.232	-4.041	-0.061	1.058	0.109	-2.772
Indonesian	-0.050	0.016	0.000	-0.161	2.006	47.076	0.603	6.450
Malaysian	0.856	7.467	0.177	3.521	-0.323	1.956	0.025	-1.330
Pakistani	1.388	7.370	0.169	3.431	-0.021	0.003	0.000	-0.051
Traditional food	-0.178	4.618	0.580	-6.616	0.001	0.000	0.000	0.047
Western Food	0.903	23.397	0.580	6.616	-0.006	0.002	0.000	-0.047
Carbonated drinks	1.190	27.110	0.624	6.899	0.008	0.002	0.000	0.045
Fresh Juice	-0.147	3.347	0.624	-6.899	-0.001	0.000	0.000	-0.045
Maybe	-0.088	0.572	0.023	-1.251	0.435	25.967	0.559	6.220
No	-0.678	14.069	0.367	-5.165	-0.561	17.682	0.251	-4.274

Categorical variables (eta2)		
	Dim.1	Dim.2
Nationality	0.244	0.561
Food	0.425	0.000
Juice	0.462	0.000
Dessert	0.386	0.558


Podobnie jak na wykresie reprezentacji zmiennych: największy wpływ na najważniejszy wymiar (dim.1) mają zmienne Food i Juice, natomiast na drugi wymiar – dwie pozostałe cechy.

Do oceny wartości własnych uzyskanych dla kolejnych wymiarów posłużę wykres osypiska. Jak widzimy, połowę wariancji da się opisać przy pomocy tylko 2 wymiarów z 7.



Przedstawienie rozkładu kategorii na płaszczyźnie uzyskanej z dwóch najważniejszych wymiarów analizy MCA. Wartości jednakowe zostały oznaczone izolinią, by ułatwić odczytanie klastrów.

```
print("wykres2 MCA: plot of variable categories")
ggplot(data = mca_obs_df, aes(x = Dim.1, y = Dim.2))+
  geom_hline(yintercept = 0, colour = "gray70")+
  geom_vline(xintercept = 0, colour = "gray70")+
  geom_point(colour = "gray50", alpha = 0.7)+
  geom_density2d(colour = "gray80")+
  geom_text(data = mca_vars_df, aes(x = Dim.1, y = Dim.2, label = rownames(mca_vars_df),
  colour = Variable))+ ggtitle("MCA plot of variables using R package FactoMineR")+
  scale_colour_discrete(name = "Variable")
```



Na wykresie widać, że klastry zazębiają się ze sobą. Mimo to można wyróżnić 2 klastry umiarkowanej jakości, które mieszczą 124/273 obiektów:

- Indian, Traditional Cuisine, Fresh Juice, No/Maybe
- Pakistani/Malaysian, Western Cuisine, Carbonated Drinks, Yes

Jak widać, Hindusi mają skłonność do dań tradycyjnych popijanych sokiem, a także nie są zbyt chętni do deserów. Możliwe jest uwzględnienie kategorii Yes w tym klastrze, wówczas klastry obejmą 190/273 obiektów, ale w zamian stracimy możliwość wyciągania wniosku z tych danych.

Drugi klaster obejmuje tylko 2 obiekty, co jest związane z niewielką liczebnością obiektów dla Malezji i Pakistanu.

Możliwe jest też utworzenie trzeciego klastra:

- Indonesian, Traditional Cuisine, Fresh Juice, Maybe

Ten klaster obejmuje jednak tylko 2 obiekty, co daje argument by te obiekty odrzucić.

Możliwe jest poprawienie jakości klastrów, poprzez zrezygnowanie z kolumny Nationality. Wówczas klastry będą prezentować się następująco:

- Traditional Cuisine, Fresh Juice, No/Maybe
- Western Cuisine, Carbonated Drinks, Yes

Udało się zaklasyfikować 221/273 obiekty.

```
> table(gr1)
grupy
  0   a   b
52 211  10
.. ..
```

Nie udało się zaklasyfikować 52 obiektów.

```
> #przypadki nieujete w grupowaniu
> subset(WYN,WYN$nowa1==0)
  Nationality      Food      Juice Dessert nowa1
3      Indian  western Food  Fresh Juice  Maybe      0
10     Indian  western Food  Fresh Juice   Yes      0
18  Malaysian Traditional food Carbonated drinks  Maybe      0
20  Malaysian  western Food  Fresh Juice  Maybe      0
21  Malaysian  western Food  Fresh Juice   Yes      0
27  Malaysian Traditional food Carbonated drinks  Maybe      0
28  Malaysian  western Food  Fresh Juice   Yes      0
29     Indian  western Food  Fresh Juice  Maybe      0
30     Indian  western Food  Fresh Juice  Maybe      0
31     Indian  western Food  Fresh Juice  Maybe      0
```

4. Wnioski

- Ze względu na bardzo dużą frekwencję Hindusów w badaniu (241/273), konieczne jest odrzucenie kolumny narodowości i skupienie się na pozostałych 3 kolumnach z danymi.
- Zastosowanie izolinii ułatwia odczytywanie klastrów z wykresu mapy czynników.
- Możliwe jest zauważenie związku między Hindusami, a tradycyjną kuchnią i piciem soku.
- Osoby, które lubią kuchnię tradycyjną, wolą sok i odmawiają deseru.
- Osoby, które lubią kuchnię zachodnią, lubią spożywać ją z napojami gazowanymi i deserami.

- Połowę wariancji problemu można wyjaśnić z użyciem dwóch wymiarów: wymiar 1 opisywany jest głównie przez kolumny Food i Juice, natomiast wymiar 2 wyłącznie przez Nationality i Dessert.
- Wymiar 1 odpowiada za ponad 1/3 wariancji w próbce. Oznacza to, że Food i Juice są najbardziej powiązanymi cechami i są najważniejszą zależnością wynikającą z danych.
- Klaster b liczy tylko 10 obiektów – jest to dopuszczalne ze względu na małą reprezentatywność próbki.
- Nie udało się poprawnie zaklasyfikować miłośników kuchni zachodniej, którzy lubią sok, a także miłośników kuchni tradycyjnej, którzy lubią napoje gazowane.