



Uniwersytet Rzeszowski
Kolegium Nauk Przyrodniczych
Instytut Informatyki

Metody Statystyki Matematycznej

Lab 1

Regresja logistyczna

Prowadzący:

Dr Lech Zaręba

Autor:

Jakub Flis

117794

1. Wstęp

Regresja logistyczna to metoda statystyczna stosowana do modelowania zależności między zmienną zależną binarną a zmiennymi niezależnymi. Pozwala przewidzieć prawdopodobieństwo wystąpienia jakiegoś zdarzenia na podstawie zmiennych niezależnych.

Regresja logistyczna modeluje logit (logarytm ilorazu szans) zmiennej zależnej jako liniową funkcję zmiennych niezależnych.

Logit nieznanego prawdopodobieństwa sukcesu p_i jest modelowany jako liniowa funkcja X_i :

$$\text{logit}(p_i) = \ln\left(\frac{p_i}{1 - p_i}\right) = \beta_1 x_{1,i} + \dots + \beta_k x_{k,i}.$$

Model posiada równoważne sformułowanie w postaci:

$$p_i = \frac{1}{1 + e^{-(\beta_1 x_{1,i} + \dots + \beta_k x_{k,i})}}.$$

Taki model regresji logistycznej wymaga, aby:

- rozpatrywane obserwacje były od siebie niezależne;
- logit(p) zależał w sposób liniowy od zmiennych objaśniających

2. Źródło danych

<https://www.kaggle.com/datasets/yasserh/heart-disease-dataset>

Dane zawierające wskaźniki dotyczące stanu zdrowia pacjentów oraz informacja czy mają choroby serca lub nie.

Liczba rekordów: 303

Liczba kolumn: 14

Zmienna zależna binarna: target (zdrowy/chory)

# age Patient's Age	# sex Patient's Gender	# cp Patient's CP Level	# trestbps Patient's Trest BPS Level	# chol Patient's Cholesterol Level
				
29 77	0 1	0 3	94 200	126 564
63	1	3	145	233
37	1	2	130	250
41	0	1	130	204
56	1	1	120	236
57	0	0	120	354
57	1	0	140	192

# fbs Patient's FBS Level	# restecg Patient's Resting ECG Levels	# thalach Patient's Thalach Levels	# exang Patient's Exang Levels	# oldpeak Patient's Old Peak History Recorded
				
0 1	0 2	71 202	0 1	0 6.2
1	0	150	0	2.3
0	1	187	0	3.5
0	0	172	0	1.4
0	1	178	0	0.8
0	1	163	1	0.6

# slope Patient's Slope Levels	# ca Patient's CA Levels	# thal Patient's Thal Levels	# target 0 - Healthy Individual 1 - Heart-Disease Patient
			
0 2	0 4	0 3	0 1
0	0	1	1
0	0	2	1
2	0	2	1
2	0	2	1

3. Przygotowanie modelu

Wybór modelu bazowego:

Bierzemy wszystkie kolumny (~) i wyraz wolny 0. Model będzie wykorzystywał rozkład logistyczny.

```
model0<-glm(X$target~.+0,data=X,family = "binomial"(link="logit"))
summary(model0)
```

Coefficients:				
	Estimate	Std. Error	z value	Pr(> z)
age	0.012771	0.019057	0.670	0.502772
sex	-1.638052	0.451880	-3.625	0.000289 ***
cp	0.849045	0.184063	4.613	3.97e-06 ***
trestbps	-0.015332	0.009815	-1.562	0.118265
chol	-0.003615	0.003766	-0.960	0.337148
fbs	-0.011519	0.525637	-0.022	0.982517
restecg	0.543176	0.341823	1.589	0.112048
thalach	0.031899	0.008441	3.779	0.000158 ***
exang	-0.892011	0.402685	-2.215	0.026749 *
oldpeak	-0.498808	0.209486	-2.381	0.017261 *
slope	0.609170	0.345914	1.761	0.078231 .
ca	-0.772491	0.189333	-4.080	4.50e-05 ***
thal	-0.843846	0.287352	-2.937	0.003318 **

Wskaźnik Aikake: 239.27.

Kolumna estimate informuje o wpływie współczynników regresji na wynik. Dla zmiennej age współczynnik wynosi około 0.01, co oznacza że przy wzroście wieku o 1, logarytm ilorazu szans rośnie o 0.01.

Największy wpływ na wynik regresji (przy zmianie wartości zmiennej o 1) mają kolumny: sex, cp, restecg, exang, oldpeak, slope, ca, thal – są to też zmienne o bardzo wąskim zakresie wartości.

Z value: test istotności współczynnika. Obliczana jako Estimate / Std. Error.

Na podstawie $\text{pr}(>|z|)$ widzimy, że współczynniki age, trestbps, chol, fbs, restecg są mało istotne statystycznie.

Przeprowadzamy regresję krokową (wsteczną i postępującą) na modelu bazowym, by ustalić najważniejsze parametry modelu z użyciem wskaźnika AIC (z parametrem $k=2$).

```
26 NAJ<-stepAIC(model0, direction = "both", steps = 1000, k = 2)
27 NAJ
28 summary(NAJ)
```

Startujemy od wartości AIC=239.27.

```
Step: AIC=234.32
x$target ~ sex + cp + trestbps + restecg + thalach + exang +
          oldpeak + slope + ca + thal - 1
```

	Df	Deviance	AIC
<none>		214.32	234.32
- slope	1	217.35	235.35
- restecg	1	217.38	235.38
- trestbps	1	217.39	235.39
+ chol	1	213.73	235.73
+ age	1	214.18	236.18
+ fbs	1	214.32	236.32
- exang	1	219.38	237.38
- oldpeak	1	220.91	238.91
- thal	1	224.51	242.51
- sex	1	229.07	247.07
- thalach	1	230.30	248.30
- ca	1	232.15	250.15
- cp	1	239.90	257.90

Model zawierający zmienne:

```
x$target ~ sex + cp + trestbps + restecg + thalach + exang +
          oldpeak + slope + ca + thal - 1
```

Posiada wskaźnik AIC=234.32. W kolumnach wynikowych <none> oznacza właśnie ten model.

Sprawdzamy wpływ dodania brakujących zmiennych, oraz wpływ usunięcia obecnych zmiennych.

Deviance jest miarą dobroci dopasowania do testowania hipotezy.

Jak widać obecny model (<none>) ma najniższy deviance ze wszystkich możliwości oraz najlepszy AIC.

```
Coefficients:
      sex      cp  trestbps  restecg  thalach  exang  oldpeak  slope      ca      thal
-1.54470  0.85741 -0.01394  0.58311  0.02907 -0.89737 -0.51230  0.60240 -0.74795 -0.85674
```

Model po regresji krokowej zawiera 10 cech (3 zostały odrzucone – chol, age, fbs).

Sprawdzony został również model z wyrazem wolnym.

```
print("najlepsze z wyrazem wolnym")
model2<-glm(X$target~.,data=X,family = "binomial")
NAJ1<-stepAIC(model2, direction = "both", steps = 1000, k = 2)
NAJ1
summary(NAJ1)
```

```
Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  2.157907   1.945343   1.109 0.267315
sex          -1.563590   0.432720  -3.613 0.000302 ***
cp             0.870475   0.182131   4.779 1.76e-06 ***
trestbps      -0.020406   0.009988  -2.043 0.041046 *
restecg        0.553402   0.339071   1.632 0.102656
thalach        0.022809   0.009395   2.428 0.015185 *
exang         -0.970656   0.403365  -2.406 0.016111 *
oldpeak       -0.558608   0.211713  -2.639 0.008327 **
slope         0.564616   0.346525   1.629 0.103236
ca            -0.763038   0.185060  -4.123 3.74e-05 ***
thal         -0.940441   0.284072  -3.311 0.000931 ***
---
```

AIC=235.08.

Model z wyrazem wolnym posiada te same zmienne i bardzo podobne wartości współczynników.

Oba modele są bardzo podobne, ale ostatecznie najlepszy jest model bez wyrazu wolnego, co prawdopodobnie ma związek z tym, że wszystkie cechy zaczynają się w skali od 0, i są na ogół pozytywnie skorelowane z prawdopodobieństwem choroby.

Dla najlepszego modelu wyznaczono przedziały ufności z użyciem confint (level=0.95).

```
CON<-Confint(NAJ)
w2<-data.frame(CON,pvalue)
colnames(w2)<-c("coefficient","95% CI lower","95% CI upper","p-value")
w2
```

```
      coefficient 95% CI lower 95% CI upper p-value
sex      -1.5446998  -2.42450747 -0.735755118 0.00031
cp         0.85741175   0.51410327  1.226406548 0.00000
trestbps  -0.01393815 -0.03010583  0.001630877 0.08361
restecg    0.58311354 -0.06960147  1.250260883 0.08194
thalach    0.02907192  0.01445247  0.044790834 0.00016
exang     -0.89736766 -1.68091820 -0.116362498 0.02380
oldpeak   -0.51230311 -0.92880995 -0.118994958 0.01268
slope      0.60239673 -0.07665157  1.275582710 0.07872
ca        -0.74794899 -1.12475548 -0.394867941 0.00005
thal     -0.85674317 -1.40439863 -0.329934740 0.00167
```

Wartości współczynników mieszczą się w szerokich przedziałach – potrzebne byłoby zwiększenie liczby obserwacji w celu poprawienia dokładności przewidywań.

Sprawdzenie ważności zmiennych (relative variable importance RVI):

```
      overall
cp      4.741313
trestbps 1.730096
restecg  1.739543
thalach  3.772214
exang    2.260421
oldpeak  2.492638
slope    1.758172
ca       4.046475
thal     3.144136
...
```

Jak widać trestbps (tętno spoczynkowe) ma niewielkie znaczenie na wynik przewidywań.

Sprawdzenie współliniowości zmiennych w modelu.

```
> vif(NAJ1)
      sex      cp trestbps restecg thalach  exang oldpeak  slope      ca      thal
1.165703 1.245034 1.065543 1.039551 1.192727 1.123495 1.402143 1.487628 1.073931 1.038523
```

Żadna zmienna nie ma $VIF(x) > 5$, co oznacza niską współliniowość w modelu – co jest pożądane.

```
LR<-lrtest(NAJ)
LR
ifelse(LR$`Pr(>Chisq)`<0.05,'
LR$`Pr(>Chisq)`[[2]]
WALD<-waldtest(NAJ)
WALD
WALD$`Pr(>F)`[[2]]
ifelse(WALD$`Pr(>F)`<0.05,"i:
```

Test stosunku wiarygodności (likelihood ratio test) porównuje dopasowanie modelu pełnego z modelem bez zmiennych predykcyjnych.

```
Likelihood ratio test

Model 1: X$target ~ sex + cp + trestbps + restecg + thalach + exang +
      oldpeak + slope + ca + thal - 1
Model 2: X$target ~ 1
#Df  LogLik Df  Chisq Pr(>Chisq)
1   10 -107.16
2    1 -208.82 -9 203.32 < 2.2e-16 ***
```

Df oznacza liczbę stopni swobody, natomiast loglik - Log-likelihood. Im wyższy loglik tym model lepiej dopasowuje się do danych.

Kolejne kolumny wynikowe przedstawiają różnice między modelami. Chisq oznacza test chi-squared liczony na podstawie dwukrotności różnicy między wartościami loglik.

Widzimy, że model pełny jest znacznie lepszy od modelu bez zmiennych, wraz z ogromną istotnością statystyczną.

Test walda to test istotności modelu z współczynnikami.

```
wald test

Model 1: X$target ~ sex + cp + trestbps + restecg + thalach + exang +
  oldpeak + slope + ca + thal - 1
Model 2: X$target ~ 1 - 1
   Res.Df  Df       F    Pr(>F)
1      293    0      NA      NA
2      303 -10  8.1141 1.404e-11 ***
```

Jak widzimy model z 10 współczynnikami ma o 10 stopni swobody więcej niż model bez współczynników. Ponownie widzimy dużą istotność statystyczną różnicy między modelami na korzyść modelu pełnego.

Wyznaczamy ROC (receiver operating characteristic) – narzędzie oceny klasyfikacyjnej modelu regresji logistycznej porównujące czułość ze specyficznością.

```
roc.plot(NAJ$y,NAJ$fitted.values)

AUC<-roc.area(NAJ1$y,NAJ1$fitted.values)
AUC
[1] 0.9232323

> AUC
$A
[1] 0.9232323


$n.total
[1] 303

$n.events
[1] 165

$n.noevents
[1] 138

$P.value
[1] 3.448073e-37
```

Wartość AUC powyżej 0.9 wskazuje na bardzo dobrą jakość modelu. Model przetestowano na wszystkich 303 obserwacjach. Jak widzimy rozkład przypadków pozytywnych i negatywnych jest zbalansowany. Model ma bardzo wysoką istotność statystyczną.



Linia przebiegająca przez połowę wykresu wyznacza granicę przewidywań losowych. Przygotowany model regresji przebiega bardzo regularnie i blisko lewego-górnego rogu wykresu, co oznacza jego bardzo dobrą jakość.

Przekształcamy logity (logarytmy szans) na postać łatwiejszą do interpretacji (odds ratio - iloraz szans) przy pomocy przekształcenia wykładniczego:

OR – odds ratio - iloraz szans mówi nam, jak zmienia się szansa wystąpienia zdarzenia ($\text{target} = 1$) w odpowiedzi na jednostkową zmianę zmiennej predykcyjnej.

```
#od ratio
ILORAZYSZANS<-exp(NAJ$coefficients)
ILORAZYSZANS
```

sex	cp	trestbps	restecg	thalach	exang	oldpeak	slope	ca	thal
0.2133759	2.3570522	0.9861585	1.7916080	1.0294986	0.4076413	0.5991142	1.8264912	0.4733364	0.4245425

Jak widzimy, dla płci szansa na $\text{target}=1$ zmniejsza się o 79% dla kobiet.

Następnie wykorzystamy przygotowany model regresji logistycznej do wyznaczenia ryzyka dla każdego pacjenta.

```
pred<-predict.glm(NAJ,X,type = "response")
pred
DF<- data.frame(fitted(NAJ),NAJ$y)
DF
```

Jak widać poniżej, dla osób z chorobą serca, ryzyko choroby serca jest bardzo wysokie, z przedziału (0.6, 0.99).


```

> DF<- data.frame(fitted(NAJ),NAJ$y)
> DF
  fitted.NAJ. NAJ.y
1  0.791212784     1
2  0.704991088     1
3  0.943742046     1
4  0.922693132     1
5  0.873891797     1
6  0.717166399     1
7  0.828777946     1
8  0.868442073     1
9  0.809063856     1
10 0.916265182     1
11 0.649108606     1
12 0.980465035     1
13 0.903705259     1
14 0.679198862     1
15 0.984785395     1
16 0.964013034     1
17 0.994041953     1

```

Jak widać poniżej, dla osób bez choroby serca, ryzyko choroby serca jest różne, z przedziału (0.01, 0.95).

```

166 0.003485002     0
167 0.005708429     0
168 0.086787249     0
169 0.074737657     0
170 0.017197738     0
171 0.569382403     0
172 0.540952793     0
173 0.564244395     0
174 0.242141594     0
175 0.006001109     0
176 0.025246326     0
177 0.081902908     0
178 0.947178371     0
179 0.020340209     0
180 0.070018033     0
181 0.039473885     0
182 0.029297824     0
183 0.930377477     0

```

Wśród osób zdrowych występują osoby, dla których przewidziano olbrzymie ryzyko zachorowania (> 0.9).

4. Ocena modelu

```
A1<-matrix(0,nrow(DF),1)
A2<-data.frame(A1)
colnames(A2)<-c("predict")
for(i in 1:nrow(DF)){
  if(DF[i,1]>=0.60){A2[i,1]=0}
  if(DF[i,1]>=0.60){A2[i,1]=1}
}
A2
DF1<-data.frame(DF,A2)
DF1
sum(DF1[2])
sum(DF1[3])
```

Powyższy kod wykorzystuje przewidziane szanse, by osobom z wysokim ryzykiem przypisać diagnozę target=1. Eksperymentalnie dobrano próg 0.6, tak aby suma wartości oczekiwanych i przewidzianych były sobie bliskie.

```
300 0.791228983    0    1
301 0.016706652    0    0
302 0.025131312    0    0
303 0.904212129    0    1
> sum(DF1[2])
[1] 165
> sum(DF1[3])
[1] 163
```

Uzyskane wartości dopisano do początkowej tabeli i zapisano w zewnętrznej tabeli.

```
logis <- cbind(logis, C=DF1[3])

write.table(logis,
file="lab1result.csv",append=TRUE,sep=";",row.names=TRUE,col.names=TRUE,dec = ",")
```

Następnie wykorzystano macierz pomyłek do oceny jakości klasyfikacji.

```
C<-confusionMatrix(factor(DF1$predict), factor(DF1$NAJ.y), positive='1')
C
```

Model uznacza się zadowalającym poziomem accuracy.

Następnie wygenerowano raport:

```
#raporty
write.table(d1, file="tab.csv", append=TRUE, sep=";", row.names=FALSE, col.names=TRUE, dec = ",")
write.table(w2, file="tab1.csv", append=TRUE, sep=";", row.names=TRUE, col.names=TRUE, dec = ",")

      Reference
Prediction 0  1
      0 118  22
      1  20 143

      Accuracy : 0.8614
      95% CI : (0.8173, 0.8982)
No Information Rate : 0.5446
P-value [Acc > NIR] : <2e-16

      Kappa : 0.7209

McNemar's Test P-value : 0.8774

      Sensitivity : 0.8667
      Specificity : 0.8551
      Pos Pred Value : 0.8773
      Neg Pred Value : 0.8429
      Prevalence : 0.5446
      Detection Rate : 0.4719
      Detection Prevalence : 0.5380
      Balanced Accuracy : 0.8609
```

5. Wnioski

- Model odznacza się zadowalającą dokładnością (86%).
- Podczas regresji krokowej odrzucono między innymi wiek oraz poziom cholesterolu, co sugeruje, że ocena tych wskaźników jest zbyt trudna by przeprowadzić regresję z ich użyciem.
- Poziom ryzyka, przy którym rzeczywiście występują choroby serca, to nie 50% tylko 60%. Sugeruje to, że model może być odrobinę zbyt czuły.
- W tym modelu zarówno fałszywe pozytywy jak i fałszywe negatywy niosą za sobą ważne informacje. Fałszywe pozytywy sugerują, że dana osoba powinna koniecznie zmienić tryb życia, by uniknąć zachorowania. Natomiast fałszywe negatywy informują, że osoba miała dużo pecha.
- Możliwe jest teraz wykorzystanie sporządzonego modelu na specjalnie przygotowanych danych, by móc wyciągnąć wnioski i porównać je z intuicyjnym rozumieniem.
- Współczynniki regresji zostały zapisane w dołączonym pliku. W takiej samej formie zapisano przewidywania oraz macierz pomyłek i wskaźniki oceny klasyfikacji.
- Ocena ważności wskaźników z użyciem współczynników regresji, jest trudna bez dokonania normalizacji.